

CERTIFICATION AIA — BLOC 3

Orchestration de pipelines de données


Workflow Orchestration avec Apache Airflow — détection de fraude bancaire

Ahmed Mehdi SEMAR


Certification AIA — Architecte en Intelligence Artificielle · Soutenance : 5 min + 15 min de questions

Contexte et objectif

- Cas métier : scorer des transactions bancaires pour détecter la fraude.
- Pipeline batch industrialisé et orchestré sous Apache Airflow.
- Deux variantes comparées : scoring via API REST vs modèle embarqué (pickle).
- Chaîne complète, modulaire et traçable de bout en bout.




Architecture d'orchestration



Airflow au centre ; sources et cibles découplées ; MLflow pour le registre de modèles.

Graphe de tâches du DAG



Chargement (TaskGroup) et notification s'exécutent en parallèle après le scoring.

Points techniques clés

1 Opérateur Airflow custom

S3ToPostgresOperator : télécharge l'objet S3 et l'insère en base via un hook SQLAlchemy.

2 Modèle robuste au déséquilibre

Pipeline imblearn + SMOTE ; choix RandomForest / XGBoost en ligne de commande.

3 Notification opérationnelle

E-mail SMTP (Gmail) avec CSV joint ; objet [FRAUD ALERT] ou [RAS] selon le batch.

4 Gestion des secrets

Connections & Variables Airflow (clé Fernet) ; aucun identifiant en dur.

Qualité, sécurité et traçabilité

1 Résilience retries + retry_delay par tâche ; les échecs unitaires de prédiction n'arrêtent pas le batch.

2 Traçabilité XCom (clés S3, compteurs) consultable par run + lineage modèle dans MLflow.

3 Sécurité / RGPD secrets chiffrés (Fernet), données et identifiants non versionnés.

4 Supervision logs détaillés par tâche dans l'UI Airflow + alerting e-mail à chaque batch.

Bilan et perspectives

- Attendus couverts : conception des flux, transformations, orchestration, qualité, sécurité, traçabilité.
- Évolution : planification récurrente (schedule_interval) immédiate à activer.
- Évolution : bascule automatique API → modèle local en cas d'indisponibilité.

Merci — questions ?

Annexe — Entraînement (train.py)

- Feature engineering : heure, jour de semaine, âge à la transaction ; suppression des colonnes identifiantes.
- Split stratifié 80/20 (fraude fortement déséquilibrée).
- Pipeline imblearn : preprocessing → SMOTE (train uniquement) → classifieur.
- Métriques de test loggées : precision, recall, F1, classification_report.
- Enregistrement MLflow : modèle fraud_detection, alias challenger.

Annexe — Configuration Airflow

Élément	Contenu
Connection aws_default	clés IAM, région
Connection postgres_default	hôte, base, identifiants
Variables FRAUD_*	URLs API, tailles de lot, préfixes S3
Variables SMTP_*	expéditeur, mot de passe d'application, destinataire
Variables MLflow	tracking URI, nom du modèle, alias